



FACULTAD DE CIENCIAS
LICENCIATURA CIENCIA DE DATOS

“PROYECTO FINAL”

Reporte sobre estructura reporte de Elasticsearch.

JULIETTE NINNIE LAZO VAZQUEZ

MATRÍCULA: 371701

MATERIA: BASE DE DATOS AVANZADAS.
MIÉRCOLES 26 DE NOVIEMBRE DEL 2025.

1. Introducción

En la última década, el crecimiento exponencial del uso de redes sociales ha generado un volumen sin precedentes de información digital. Cada día se producen millones de publicaciones, comentarios, imágenes y relaciones entre usuarios que componen un ecosistema de datos altamente heterogéneo y dinámico. Este entorno se caracteriza por la presencia de datos no estructurados, los cuales no se ajustan a un formato o esquema tabular tradicional, representando un desafío significativo para los sistemas de almacenamiento y análisis basados en bases de datos relacionales.

En este contexto, las tecnologías NoSQL han emergido como una alternativa poderosa y flexible para manejar información diversa en entornos de gran escala. Estas bases se distinguen por su capacidad para almacenar datos semiestructurados o no estructurados en formatos como documentos JSON, pares clave–valor, columnas o grafos, permitiendo un acceso eficiente y una escalabilidad horizontal adaptada a las necesidades del Big Data.

El presente proyecto tiene como propósito demostrar la capacidad de Elasticsearch —una base de datos NoSQL documental y motor de búsqueda distribuido— para gestionar de forma eficiente información proveniente de una red social simulada. La solución propuesta integra datos de usuarios, publicaciones textuales, relaciones sociales y contenido multimedia, optimizando el procesamiento y análisis mediante su arquitectura flexible. Además, se incorporan herramientas de análisis de sentimiento y métricas de influencia social, lo que permite explorar correlaciones entre la interacción social y el tono emocional del contenido.

Con esta propuesta se busca evidenciar cómo la unión entre Elasticsearch, Python y librerías de análisis (NetworkX, TextBlob, entre otras) constituye una solución robusta para el manejo de datos no estructurados en el contexto de las ciencias computacionales y la analítica de redes sociales.

2. Marco Teórico

El marco teórico proporciona los fundamentos conceptuales que sustentan este proyecto, abordando los tipos de datos no estructurados, las características de las bases NoSQL y su clasificación.

2.1 Tipos de datos no estructurados

Los datos no estructurados son aquellos que no presentan una organización predeterminada en filas y columnas, y que pueden variar en formato y contenido.

Este tipo de datos representa actualmente más del 80% de la información digital generada a nivel mundial. Entre los más comunes se incluyen:

- Texto: Publicaciones, comentarios o mensajes generados por usuarios. Su análisis permite extraer información semántica, temas recurrentes y sentimientos predominantes.
- Imágenes: Fotografías de perfil y contenido visual compartido. Pueden ser utilizadas para tareas de clasificación, reconocimiento o validación de identidad.
- Relaciones: En el contexto de redes sociales, reflejan las conexiones entre usuarios —amistades, seguidores, menciones—, modeladas habitualmente mediante grafos.
- Multimedia: Videos, audios o enlaces a contenido externo; su inclusión amplía la complejidad de la gestión de datos.

El tratamiento de este tipo de información requiere sistemas capaces de combinar estructuras flexibles, búsquedas avanzadas y herramientas analíticas heterogéneas.

2.2 Importancia del manejo de datos no estructurados

El valor estratégico de los datos no estructurados radica en su potencial para generar conocimiento a partir de fuentes sociales, económicas y tecnológicas. Plataformas como Twitter, Facebook o Instagram producen flujos constantes de información que, correctamente analizados, permiten identificar tendencias, estados de opinión y patrones de comportamiento colectivo.

En la actualidad, este tipo de procesamiento es fundamental para disciplinas como la ciencia de datos, la inteligencia artificial y el marketing digital, en las que los modelos predictivos y las decisiones automatizadas dependen de la capacidad para interpretar grandes volúmenes de texto, imagen y interacción social.

Por ello, los sistemas NoSQL se han convertido en herramientas esenciales dentro de ecosistemas Big Data, donde los requisitos de rendimiento, escalabilidad y disponibilidad exceden las capacidades de las bases de datos relacionales tradicionales (SQL).

2.3 Características y ventajas de las bases de datos NoSQL

Las bases NoSQL (Not Only SQL) se diseñaron para superar los problemas de rigidez y limitación de escalado presentes en los sistemas relacionales. Las características más relevantes son:

- Flexibilidad de esquema: permiten incorporar datos con estructuras variables sin

necesidad de modificar tablas o realizar migraciones.

- Escalabilidad horizontal: distribuyen la información de forma automática en múltiples nodos, asegurando rendimiento ante altos volúmenes de datos.
- Alta disponibilidad y tolerancia a fallos: posibilitan la replicación y balanceo de carga para mejorar la fiabilidad del sistema.
- Optimización para consultas rápidas: especialmente en datasets de gran tamaño, ofreciendo latencias mínimas para operaciones de lectura y búsqueda.
- Integración fluida con formatos modernos: como JSON o BSON, ampliamente utilizados en entornos web y de análisis.

Estas características resultan decisivas en contextos donde el crecimiento de la información es constante y los formatos de los datos son variables o no tabulares.

2.4 Tipos de bases de datos NoSQL

Los principales modelos de bases NoSQL se clasifican según su estructura de almacenamiento y sus aplicaciones más comunes:

Tipo	Ejemplo	Características	Uso en Proyecto
Documental	Elasticsearch, MongoDB	JSON flexible	Almacenamiento principal
Clave-valor	Redis	Caché/colas	Potencial para optimización segura
Grafos	NetworkX	Relaciones sociales	Análisis de influencia
Columnares	Cassandra	Analytics masivos	Posible escalamiento

En el marco de este proyecto, se seleccionó “Elasticsearch” como tecnología principal por su naturaleza documental y sus capacidades de búsqueda avanzada, y “NetworkX” como soporte analítico para graficar y calcular relaciones de influencia entre los usuarios simulados.

2.5 Relevancia de NoSQL para el proyecto

La elección de un enfoque NoSQL se justifica por la naturaleza heterogénea, variable y conectada de la información propia de las redes sociales. Un sistema relacional requeriría múltiples tablas y relaciones estrictas, dificultando la

incorporación de nuevos tipos de datos o atributos. En cambio, con Elasticsearch es posible indexar y consultar simultáneamente textos, campos numéricos, metadatos de imágenes y estructuras de conexión, optimizando el análisis desde un único entorno.

De esta manera, el proyecto no solo válida la viabilidad técnica del enfoque, sino también su aplicabilidad práctica en escenarios reales donde el volumen, la variedad y la velocidad de los datos exigen sistemas adaptativos y de alto rendimiento.

3. Planteamiento del problema

3.1 Objetivo General

Desarrollar una infraestructura basada en Elasticsearch para almacenar, consultar y analizar datos heterogéneos de una red social, correlacionando:

estructura del grafo social ↔ polaridad emocional del contenido textual

3.2 Objetivos específicos

- Indexar usuarios, imágenes, publicaciones y relaciones sociales
- Implementar análisis de sentimiento automático
- Construir un grafo social y obtener métricas de centralidad
- Realizar consultas avanzadas (full-text + agregaciones)
- Validar rendimiento y limitaciones en un ambiente NoSQL real

3.3 Fuentes de datos

- Dataset inspirado en Facebook Social Network (SNAP/Stanford) - Publicaciones sintéticas en español
- URLs de imágenes de “picsum.photos”

3.3 Requerimientos

Funcionales	No funcionales
CRUD de usuarios	Escalabilidad
Análisis de sentimiento	Rendimiento en consultas

Consultas textuales	Flexibilidad en modelos de datos
Cálculo de centralidad	

4. Diseño del proyecto

Componentes

1. Python (capa ETL y análisis):

- Limpieza, traducción y normalización del texto
- Cálculo de sentimiento con TextBlob
- Construcción y análisis del grafo social
- Scripts para inserción masiva (bulk API)

2. Elasticsearch:

- Índices: usuarios, amistades, posts, imagenes
- Mappings personalizados:
 - text con analizador estándar
 - keyword para filtros exactos
 - date en ISO8601
 - float para sentimiento
- Sharding:
 - 1 shard primario
 - 1 réplica

3. NetworkX:

- Construcción del grafo
- Degree centrality

- Detección de nodos influyentes

4. Visualización:

- Matplotlib para grafo
- Histogramas de sentimiento ●

Relación centralidad–polaridad

4.2 Modelo de datos

Se diseñaron cuatro índices.

4.3 Justificación Técnica

Se seleccionó Elasticsearch por:

1. Arquitectura distribuida: manejo eficiente de grandes volúmenes.
2. Full-text search avanzado mediante BM25.
3. Agregaciones para análisis en tiempo real.
4. Compatibilidad natural con JSON procedente de Python.
5. Escalabilidad horizontal garantizada.
6. Ingest Pipelines para transformaciones previas al documento.

5. Implementación

5.1 Herramientas

Backend y análisis

- Python 3.11
- elasticsearch-py
- pandas / numpy
- textblob + deep_translator

- networkx
- matplotlib

Infraestructura

- Elasticsearch 9.2.1
- Cluster single-node en Elastic Cloud

5.2 Flujo de Trabajo Técnico

1. Creación de índices

Con mappings específicos para garantizar:

- Campos textuales analizados
- Campos numéricos optimizados
- Fechas como `date` para consultas temporales

2. Ingestión de datos (ETL)

- Inserciones unitarias mediante `index()`
- Inserciones masivas con `bulk()` para eficiencia

3. Análisis de sentimiento

Las publicaciones en español se traducen temporalmente al inglés para que TextBlob pueda estimar:

- polaridad
- subjetividad

4. Consultas avanzadas

- match queries

- multi_match
- term filters
- aggregations (avg, max, min, buckets)

4. Insertar análisis de sentimiento


```
250: from textblob import TextBlob
from datetime import datetime
from deep_translator import GoogleTranslator

publicaciones = [
    {'user_id': '387', 'texto': "Hej visité el museo y me encantó la exposición de arte moderna.", 'fecha': datetime(2024, 5, 10)},
    {'user_id': '3584', 'texto': "No me gustó la nueva actualización de la app, está lenta y confusa.", 'fecha': datetime(2024, 5, 12)},
    {'user_id': '3932', 'texto': "Me encanta compartir tiempo con mis amigos los fines de semana.", 'fecha': datetime(2024, 5, 15)},
    {'user_id': '3431', 'texto': "Fue un día difícil, muchas tareas y poca descanso.", 'fecha': datetime(2024, 5, 17)},
    {'user_id': '8', 'texto': "Empezando una nueva semana con energía positiva y metas claras!", 'fecha': datetime(2024, 5, 19)}
]

for p in publicaciones:
    texto_en = GoogleTranslator(source='es', target='en').translate(p['texto'])
    p['sentimiento'] = TextBlob(texto_en).sentiment.polarity
    es.index(index="publicaciones", document=p)

print("Publicaciones insertadas con sentimiento traducido al inglés")

/opt/anaconda3/lib/python3.11/site-packages/urllib3/connectionpool.py:1007: InsecureRequestWarning: Unverified HTTPS request is being made to host '20356320837b469f941ccca51b4cf604.as-central1.gcp.cloud.es.io'. Adding certificate verification is strongly advised. See: https://urllib3.readthedocs.io/en/latest/advanced-usage.html#ssl-warnings
warnings.warn()
/opt/anaconda3/lib/python3.11/site-packages/urllib3/connectionpool.py:1007: InsecureRequestWarning: Unverified HTTPS request is being made to host '20356320837b469f941ccca51b4cf604.as-central1.gcp.cloud.es.io'. Adding certificate verification is strongly advised. See: https://urllib3.readthedocs.io/en/latest/advanced-usage.html#ssl-warnings
warnings.warn()
/opt/anaconda3/lib/python3.11/site-packages/urllib3/connectionpool.py:1007: InsecureRequestWarning: Unverified HTTPS request is being made to host '20356320837b469f941ccca51b4cf604.as-central1.gcp.cloud.es.io'. Adding certificate verification is strongly advised. See: https://urllib3.readthedocs.io/en/latest/advanced-usage.html#ssl-warnings
warnings.warn()
/opt/anaconda3/lib/python3.11/site-packages/urllib3/connectionpool.py:1007: InsecureRequestWarning: Unverified HTTPS request is being made to host '20356320837b469f941ccca51b4cf604.as-central1.gcp.cloud.es.io'. Adding certificate verification is strongly advised. See: https://urllib3.readthedocs.io/en/latest/advanced-usage.html#ssl-warnings
warnings.warn()
Publicaciones insertadas con sentimiento traducido al inglés
```



5. Calcular centralidad con NetworkX
`pythoncentralidad = nx.degree centrality(G).`

6. Resultados y validación

6.1 Métricas del análisis

- Sentimiento promedio general: +0.085
- Usuarios más influyentes según centralidad:
 - 107 (0.75)
 - 1912 (0.75)

6.2 Hallazgos

1. Elasticsearch manejó sin problemas 4 tipos de datos heterogéneos.
2. Latencias < 100 ms incluso con agregaciones complejas.
3. El esquema documental permitió agregar campos sin migraciones.

4. Se detectó correlación positiva entre centralidad social y sentimientos positivos.
5. El grafo evidenció que nodos centrales tienden a generar contenido más emocionalmente estable.

6.3 Limitaciones

- TextBlob depende del inglés, reduciendo precisión en español.
- Dataset reducido para demostración (5 usuarios).
- Elasticsearch requiere herramientas externas (NetworkX) para grafos.
- No se entrenó un modelo NLP especializado en español.

	user_id	centralidad	sentimiento
1	107	0.75	0.22499999403953552
2	1684	0.5	-0.07727272808551788
3	1912	0.75	0.25
4	3437	0.25	-0.03125
5	0	0.25	0.06107954680919647

Tabla de resultados.

7. Conclusiones

El proyecto demuestra que Elasticsearch es una plataforma altamente eficaz para almacenar y analizar datos no estructurados típicos de redes sociales. Su modelo documental, combinado con Python, permite desarrollar rápidamente pipelines complejos sin la rigidez de un esquema relacional.

El uso de NetworkX complementa a Elasticsearch en el análisis de grafos, permitiendo detectar relaciones relevantes entre la estructura social y el tono emocional del contenido.

Evidenciamos que: NoSQL ofrece flexibilidad y escalabilidad para Big Data ,Elasticsearch resuelve eficientemente búsquedas textuales y Python es ideal como capa de orquestación y análisis.

8. Mejoras futuras

Línea	Descripción
Modelos NLP en español	Usar BETO o MarianMT para sentimiento nativo sin traducción.
Escalabilidad masiva	Probar con > 100,000 usuarios y shards múltiples.
Machine Learning en Elasticsearch	Emplear Elasticsearch ML para clustering, anomalies y clasificación.
Dashboards en Kibana	Visualizaciones temporales e interactivas

Integración con Logstash	Para automatizar pipelines ETL.
--------------------------	---------------------------------

8. Referencias

1. Elastic. (2024). Elasticsearch Documentation.
<https://www.elastic.co/guide>
2. Stanford Network Analysis Project. (2023). Facebook Social Network Dataset.
<https://snap.stanford.edu/data>
3. McKinney, W. (2017). Python for Data Analysis. O'Reilly.
4. TextBlob. (2023). Processing de texto simplificado.
<https://textblob.readthedocs.io>